


Machine Learning Pipelines With scikit-learn

Fei GAO
Mai 2026



01


Machine Learning predictive data analysis



Données historique






Mémorisation /
apprentissage



Nouvelles données



Généralisation /
Prédiction



APPRENTISSAGE SUPERVISÉ

Features + Label

$(X_1, X_2, X_3, X_4, \dots) (Y)$

APPRENTISSAGE NON SUPERVISÉ

Features + ~~Label~~

$(X_1, X_2, X_3, X_4, \dots) (\text{PAS d}'Y)$




Problématique de l'analyse prédictive supervisée

- Y : label
- $X_1, X_2, \dots$: features
- Nous cherchons $f()$: une fonction qui essaie d'établir la relation $Y = f(X_1, X_2, \dots)$ **pour faire de la prédiction**
- $f()$ doit être aussi précise que possible pour pouvoir prédire sur les nouvelles données



Les principales familles


CLASSICAL MACHINE LEARNING



Usuel MACHINE LEARNING ALGORITHMS

Linear Regression

Linear Regression tends to establish a relationship between a dependent variable(Y) and one or more independent variable(X) by finding the best fit of the straight line.




Regressor problems

Usuel MACHINE LEARNING ALGORITHMS

Logistic Regression

The logistic regression technique involves the dependent variable, which can be represented in the binary (0 or 1, true or false, yes or no) values or the probability of a successful or fail event.




Classification problems

Usuel MACHINE LEARNING ALGORITHMS

Decision Tree

The decision tree works on an if-then statement. Decision tree tries to solve a problem by using tree representation




Classification as well as Regressor problems

Usuel MACHINE LEARNING ALGORITHMS

Random Forest

Random Forest is an ensemble machine learning algorithm that follows the bootstrapping technique. Random forest randomly selects a set of features that are used to decide the best split at each node of the decision tree.




Classification as well as Regressor problems

Usuel MACHINE LEARNING ALGORITHMS

Support Vector Machine

SVM tries to find a line/hyperplane (in multidimensional space) that separates these two classes. Then it classifies the new point depending on whether it lies on the positive or negative side of the hyperplane depending on the classes to predict.



Classification as well as Regressor problems

Usuel MACHINE LEARNING ALGORITHMS


K Nearest Neighbor

In k-NN classification, the output is a class membership. An object is classified by a plurality vote of its neighbors, with the object being assigned to the class most common among its k nearest neighbors.

It does not create a generalized model during the time of training.

Testing is very costly.


Classification as well as Regressor problems



Usuel MACHINE LEARNING ALGORITHMS

Gradient Boosting

XGBoost is a decision-tree-based ensemble Machine Learning algorithm that uses a gradient boosting framework. The approach consists in using a gradient descent to minimize the empirical risk



Classification as well as Regressor problems

Usuel MACHINE LEARNING ALGORITHMS

Naive Bayes Classifier

It is a classification technique based on Bayes' Theorem with an assumption of independence among predictors. In simple terms, a Naive Bayes classifier assumes that the presence of a particular feature in a class is unrelated to the presence of any other feature.

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Diagram illustrating the Naive Bayes Classifier formula with labels:

- Posterior: $P(A|B)$
- Likelihood: $P(B|A)$
- Prior: $P(A)$
- Normalizing constant: $P(B)$


$$P(B) = \sum_Y P(B|A)P(A)$$

Classification problems

Usuel MACHINE LEARNING ALGORITHMS

Neural Network

As neural suggests, they are braininspired systems which are intended to replicate the way that we humans learn. NNs consist of input and output layers, as well as a hidden layer consisting of units that transform the input.



Classification as well as Regressor problems

Pourquoi existe-t-il autant d'algorithmes ?

Le « théorème » du « No Free Lunch »

Il n'existe pas d'algorithme qui soit le meilleur quelque soit le problème d'apprentissage...



Comprendre la décomposition biais-variance

- Défis : Equilibre
 - Capacité du modèle à s'adapter aux données d'entraînement
 - Capacité à généraliser sur de nouvelles données
- Décomposition biais-variance



Schéma typique (standard) de l'analyse prédictive supervisée

Y : variable cible

X1, X2, ... : variables explicatives

f(.) une fonction qui essaie d'établir la relation $Y = f(X1, X2, \dots)$

f(.) doit être « aussi précise que possible »...



Construction de la fonction f(.) à partir des données d'apprentissage

Training set

A small thumbnail image of a data table with multiple columns and rows, representing the training set.

$$Y = f(X1, X2, \dots) + \epsilon$$

Application du modèle (prédiction) sur l'ensemble de test

Validation set

A small thumbnail image of a data table with multiple columns and rows, representing the validation set.

$$(Y, \hat{Y})$$

Y : valeurs observées

$\hat{Y}$: valeurs prédites par f(.)

Mesures de **performances** par confrontation entre Y et $\hat{Y}$: matrice de confusion + mesures

Age	Sex	Height	Weight	Heart rate	Cholesterol	Diabetes
1	M	178.0	70.0	72	160	0
2	F	165.0	55.0	68	140	0
3	M	180.0	75.0	75	170	0
4	F	160.0	50.0	65	130	0
5	M	175.0	68.0	70	150	0
6	F	162.0	52.0	66	135	0
7	M	179.0	72.0	73	165	0
8	F	164.0	54.0	69	145	0
9	M	177.0	69.0	71	155	0
10	F	161.0	51.0	67	138	0
11	M	176.0	67.0	69	148	0
12	F	163.0	53.0	68	142	0
13	M	174.0	66.0	70	152	0
14	F	166.0	56.0	70	158	0
15	M	172.0	64.0	68	145	0
16	F	167.0	57.0	71	160	0
17	M	171.0	63.0	67	143	0
18	F	168.0	58.0	72	162	0
19	M	173.0	65.0	69	147	0
20	F	169.0	59.0	73	164	0
21	M	170.0	62.0	66	141	0
22	F	170.0	60.0	74	166	0
23	M	172.0	64.0	70	154	0
24	F	165.0	55.0	69	144	0
25	M	175.0	67.0	71	156	0
26	F	164.0	54.0	68	142	0
27	M	176.0	68.0	72	159	0
28	F	166.0	56.0	70	157	0
29	M	174.0	66.0	69	146	0
30	F	168.0	58.0	71	161	0
31	M	171.0	63.0	68	143	0
32	F	169.0	59.0	72	163	0
33	M	173.0	65.0	70	155	0
34	F	167.0	57.0	71	160	0
35	M	170.0	62.0	67	141	0
36	F	171.0	61.0	73	167	0
37	M	172.0	64.0	69	147	0
38	F	165.0	55.0	70	158	0
39	M	175.0	67.0	71	156	0
40	F	164.0	54.0	68	142	0
41	M	176.0	68.0	72	159	0
42	F	166.0	56.0	70	157	0
43	M	174.0	66.0	69	146	0
44	F	168.0	58.0	71	161	0
45	M	171.0	63.0	68	143	0
46	F	169.0	59.0	72	163	0
47	M	173.0	65.0	70	155	0
48	F	167.0	57.0	71	160	0
49	M	170.0	62.0	67	141	0
50	F	171.0	61.0	73	167	0

Metrics Regression

1

MAE : Mean Average Error

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

2

RMSE : Root Mean Squared Error

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

3

Root Mean Squared Logarithmic Error

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum (\log(1 + \text{prédiction}) - \log(1 + \text{cible}))^2}$$

4

Autres mesures

Mean Squared Error, Weigthed Mean Average Error, ...

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\text{prédiction}_i - \text{cible}_i)^2$$

Metrics Classification

1. Accuracy, Precision, Recall...

$$\text{Accuracy} = (TP+TN)/(TP+FP+FN+TN)$$

Precision = $TP/(TP+FP)$: is the proportion of all positive cases that were correctly classified => **FP intolerable**

Sensitivity/Recall = $(TP)/(TP+FN)$ => **FN intolerable**

Specificity = $TN/(TN+FP)$: is the proportion of all negative cases that were correctly classified

False positive rate (FPR) = $1 - \text{specificity} = 1 - (TN/(TN+FP))$: is the proportion of false positives among

2

$$F_1 = 2 * \frac{\text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$


Plus d'information :

<https://towardsdatascience.com/the-5-classification-evaluation-metrics-you-must-know-aa97784ff226>

3. AUC

AUC ROC indicates how well the probabilities from the positive classes are separated from the negative classes => Allowing threshold selection

		Actual	
		Positive	Negative
Predicted	Positive	True Positive	False Positive
	Negative	False Negative	True Negative




Interaction

- Une promotion (variable 1) augmente les ventes de 10 unités.
- La publicité (variable 2) augmente les ventes de 15 unités.
- Cependant, si vous combinez une promotion **et** une publicité, les ventes augmentent de 40 unités.
- Ici, l'effet combiné (40) est supérieur à la somme des effets individuels (10 + 15 = 25).


Modèle : $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \epsilon$

Si $\beta_3 > 0$, cela signifie qu'il existe une interaction amplificatrice entre x_1 et x_2 .

Comparison: Linear Model vs. B-Spline Model on Non-linear Data



Breakdown of B-Spline into 5 Individual Cubic Polynomial Segments



Méthode	Type de relation	Quand l'utiliser
Interactions	Effet de X1 sur Y dépendant de X2	Quand il existe une relation forte entre deux variables (effets combinés) ou à tester avec une hypothèse.
Polynomial Features	Une variable numérique $\rightarrow Y$	Quand la relation non linéaire est globale et simple (par exemple, courbe quadratique ou cubique).
Splines	Une variable numérique $\rightarrow Y$	Quand la relation non linéaire est complexe et locale (varie dans différentes parties des données).

Processus général d'un problème de data science

1

Définition de la cible et des variables explicatives

- Identification ou construction de la cible
- Identification des variables explicatives

2

Construction du jeu de données

- Filtres de la population concernée
- Exploration et visualisation

3

Préparation des données

- Feature Engineering : création de variables explicatives **metier et DS**
- Traitement des valeurs manquantes
- Encodage numérique des variables catégoriques **et La mise à l'échelle**
- Séparation des données en échantillons

4


Entraînement du modèle

- Sélection du meilleur jeu de paramètres
- Entraînement du modèle

Résultats et performance du modèle


- Application du modèle sur l'échantillon de test
- Etude des caractéristiques clés du modèle

BUILDING THE MACHINE LEARNING MODEL



La mise à l'échelle

Name	Weight	Price
Orange	15	1
Apple	18	3
Banana	12	2
Grape	10	5



La mise à l'échelle

Sr No.	Algorithms	Feature Scaling
1.	Linear/Non-Linear Regressions	Yes
2.	Logistic Regression	Yes
3.	KNN	Yes
4.	SVM	Yes
5.	Neural Networks	Yes
6.	K-means clustering	Yes
7.	CART	No
8.	Random Forests	No
9.	Gradient Boosted Decision Trees	No
10.	Naïve Bayes	NO
11.	PCA	Yes
12.	SVD	Yes
13.	Factorization Machines	Yes

Fig: Feature Scaling requires based on Machine Learning

Schéma typique (standard) de l'analyse prédictive supervisée

Y : variable cible

X1, X2, ... : variables explicatives

f(.) une fonction qui essaie d'établir la relation $Y = f(X1, X2, \dots)$

f(.) doit être « aussi précise que possible »...



Ensemble
d'apprentissage
Training set

Construction de la fonction f(.) à
partir des données d'apprentissage

$$Y = f(X1, X2, \dots) + \epsilon$$

Application du modèle (prédiction)
sur l'ensemble de test

Test set

$$(Y, \hat{Y})$$

Mesures de **performances**
par confrontation entre Y
et $\hat{Y}$: matrice de
confusion + mesures


Y : valeurs observées
 $\hat{Y}$: valeurs prédites par f(.)

patient	sex	age	height	weight	apgar1	apgar2	ventil	status
0	0	35	153.5	65.521	92	92	144	0 positive
1	0	36	159.78	67.255	95	95	99	0 negative
2	0	34	153.3	67.72	92	92	145	0 positive
3	1	36	172.35	91.587	95	95	99	0 negative
4	0	43	164.3	72.556	91	91	117	0 positive
5	1	19	170.6	73.9	92.55	99	110	0 negative
6	0	33	150	58.024	90	90	70	0 positive
10	0	37	159.2	67.238	99	99	120	0 negative
11	0	39	165.9	67.254	93	93	107	0 positive
12	0	36	157	67.232	94	94	120	0 positive
13	1	36	174	97.16	97.254	99	100	0 negative
14	0	39	165.9	67.232	94	94	120	0 positive
15	0	36	157	67.232	94	94	120	0 positive
16	1	36	174	97.16	97.254	99	100	0 negative
17	0	36	157	67.232	94	94	120	0 positive
18	0	36	157	67.232	94	94	120	0 positive
19	0	36	157	67.232	94	94	120	0 positive
20	0	36	157	67.232	94	94	120	0 positive
21	0	36	157	67.232	94	94	120	0 positive
22	0	36	157	67.232	94	94	120	0 positive
23	0	36	157	67.232	94	94	120	0 positive
24	0	36	157	67.232	94	94	120	0 positive
25	0	36	157	67.232	94	94	120	0 positive
26	0	36	157	67.232	94	94	120	0 positive
27	0	36	157	67.232	94	94	120	0 positive
28	0	36	157	67.232	94	94	120	0 positive
29	0	36	157	67.232	94	94	120	0 positive
30	0	36	157	67.232	94	94	120	0 positive
31	0	36	157	67.232	94	94	120	0 positive
32	0	36	157	67.232	94	94	120	0 positive
33	0	36	157	67.232	94	94	120	0 positive
34	0	36	157	67.232	94	94	120	0 positive
35	0	36	157	67.232	94	94	120	0 positive
36	0	36	157	67.232	94	94	120	0 positive
37	0	36	157	67.232	94	94	120	0 positive
38	0	36	157	67.232	94	94	120	0 positive
39	0	36	157	67.232	94	94	120	0 positive
40	0	36	157	67.232	94	94	120	0 positive
41	0	36	157	67.232	94	94	120	0 positive
42	0	36	157	67.232	94	94	120	0 positive
43	0	36	157	67.232	94	94	120	0 positive
44	0	36	157	67.232	94	94	120	0 positive
45	0	36	157	67.232	94	94	120	0 positive
46	0	36	157	67.232	94	94	120	0 positive
47	0	36	157	67.232	94	94	120	0 positive
48	0	36	157	67.232	94	94	120	0 positive
49	0	36	157	67.232	94	94	120	0 positive
50	0	36	157	67.232	94	94	120	0 positive
51	0	36	157	67.232	94	94	120	0 positive
52	0	36	157	67.232	94	94	120	0 positive
53	0	36	157	67.232	94	94	120	0 positive
54	0	36	157	67.232	94	94	120	0 positive
55	0	36	157	67.232	94	94	120	0 positive
56	0	36	157	67.232	94	94	120	0 positive
57	0	36	157	67.232	94	94	120	0 positive
58	0	36	157	67.232	94	94	120	0 positive
59	0	36	157	67.232	94	94	120	0 positive
60	0	36	157	67.232	94	94	120	0 positive
61	0	36	157	67.232	94	94	120	0 positive
62	0	36	157	67.232	94	94	120	0 positive
63	0	36	157	67.232	94	94	120	0 positive
64	0	36	157	67.232	94	94	120	0 positive
65	0	36	157	67.232	94	94	120	0 positive
66	0	36	157	67.232	94	94	120	0 positive
67	0	36	157	67.232	94	94	120	0 positive
68	0	36	157	67.232	94	94	120	0 positive
69	0	36	157	67.232	94	94	120	0 positive
70	0	36	157	67.232	94	94	120	0 positive
71	0	36	157	67.232	94	94	120	0 positive
72	0	36	157	67.232	94	94	120	0 positive
73	0	36	157	67.232	94	94	120	0 positive
74	0	36	157	67.232	94	94	120	0 positive
75	0	36	157	67.232	94	94	120	0 positive
76	0	36	157	67.232	94	94	120	0 positive
77	0	36	157	67.232	94	94	120	0 positive
78	0	36	157	67.232	94	94	120	0 positive
79	0	36	157	67.232	94	94	120	0 positive
80	0	36	157	67.232	94	94	120	0 positive
81	0	36	157	67.232	94	94	120	0 positive
82	0	36	157	67.232	94	94	120	0 positive
83	0	36	157	67.232	94	94	120	0 positive
84	0	36	157	67.232	94	94	120	0 positive
85	0	36	157	67.232	94	94	120	0 positive
86	0	36	157	67.232	94	94	120	0 positive
87	0	36	157	67.232	94	94	120	0 positive
88	0	36	157	67.232	94	94	120	0 positive
89	0	36	157	67.232	94	94	120	0 positive
90	0	36	157	67.232	94	94	120	0 positive
91	0	36	157	67.232	94	94	120	0 positive
92	0	36	157	67.232	94	94	120	0 positive
93	0	36	157	67.232	94	94	120	0 positive
94	0	36	157	67.232	94	94	120	0 positive
95	0	36	157	67.232	94	94	120	0 positive
96	0	36	157	67.232	94	94	120	0 positive
97	0	36	157	67.232	94	94	120	0 positive
98	0	36	157	67.232	94	94	120	0 positive
99	0	36	157	67.232	94	94	120	0 positive

Ensemble
de données
(dataset)


Ensemble de test

Cross validation



Model cross-validation

Différentes méthodes pour s'assurer que le modèle « apprend » bien, qu'il « généralise »




Idée de la validation croisée pour comparer la performance des modèles, indépendamment des « individus » utilisés pour apprendre (risque si l'on utilise 1 seul jeu d'apprentissage).


Habituellement, on utilise entre 5 ou 10 « folds ».




BUILDING THE MACHINE LEARNING MODEL



Cubic Spline



B-Spline



B-spline de degré 3 (cubic B-spline)

Si vous avez des nœuds $t = [1, 2, 3, 4, 5]$, une cubic B-spline est définie par la formule récursive :

$$B_{i,3}(x) = \frac{x - t_i}{t_{i+3} - t_i} B_{i,2}(x) + \frac{t_{i+4} - x}{t_{i+4} - t_{i+1}} B_{i+1,2}(x),$$

où $B_{i,2}(x)$ est une B-spline de degré 2.

Cubic spline (non-B-spline)

Pour les mêmes nœuds, une cubic spline s'écrit explicitement comme :

$$f(x) = a_i(x - t_i)^3 + b_i(x - t_i)^2 + c_i(x - t_i) + d_i, \quad \text{si } t_i \leq x \leq t_{i+1}.$$


Les coefficients a_i, b_i, c_i, d_i sont calculés en résolvant un système linéaire basé sur les conditions de continuité.

$$B_i(x) = a_i(x - k_i)^3 + b_i(x - k_i)^2 + c_i(x - k_i) + d_i, \quad \text{si } k_i \leq x \leq k_{i+1}.$$


For B-splines: $\text{df} = k + \text{degree}$ if you specify the knots or $k = \text{df} - \text{degree}$ if you specify the degrees of freedom and the degree. For natural (restricted) cubic splines: $\text{df} = k - 1$ if you specify the knots or $k = \text{df} + 1$ if you specify the degrees of freedom.

As an example: A cubic spline (degree = 3) with 4 (internal) knots will have $\text{df} = 4 + 3 = 7$ degrees of freedom. Or: A cubic spline (degree = 3) with 5 degrees of freedom will have $k = 5 - 3 = 2$ knots.

Let's see some illustrations. In the scatterplots below you see some artificial data together with the spline fits of different degrees but the same amount of knots ($k = 3$). The knots are indicated by dashed vertical lines (Boundary knots by red dashed lines) and are placed at the 25th, 50th and 75th percentile of x . The first plot shows a linear spline (degree = 1), the second one a quadratic spline (degree = 2) and the third is a cubic spline with degree = 3.




In the next plot, you see three cubic splines with different degrees of freedom. As before, the knots are shown as dashed vertical lines. With increasing degrees of freedom, the number of knots gets larger (from 1 to 3 to 5). The spline gets wigglier although the difference is only really noticeable between the first and second plot.



spline function procedures

A cubic spline function, with three knots (τ_1, τ_2, τ_3) will have 7 degrees of freedom. Using representation given in Eq. [2](#), the function can be written as:

$$f(X) = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \beta_4 (X - \tau_1)^3 + \beta_5 (X - \tau_2)^3 + \beta_6 (X - \tau_3)^3$$



Detecting Interaction Effects



REF :


<https://bookdown.org/max/FES/detecting-interaction-effects.html>



Excercise



The Requirements Surrounding ML Infrastructure



Expressions régulières (1/1)

- **ion** : recherche les mots qui contiennent la chaîne "ion", dans n'importe quelle position
- **ion\$** : mots se terminant par "ion" (\$=fin de mot)
- **^anti** : recherche tous les mots commençant par "anti" (^=début de mot)
- **^maison\$** : recherche exactement le mot "maison"
- **p.r** : recherche les mots qui contiennent un "p", suivi d'une lettre quelconque, puis d'un "r" (le point correspond à n'importe quel caractère)
- **^p...r\$** : mots commençant par "p", suivi de trois lettres quelconques, et finissant par "r" (le symbole . dans une regex correspond à n'importe quel caractère)
- **^p.*r\$** : mots commençant par "p" et finissant par "r" (*= répétitions – 0 ou plusieurs fois – du caractère précédent, ici '.', donc n'importe quel caractère)
- **oid|ion|ein** : recherche les mots qui contiennent (au moins) une des trois chaînes "iod", "ion" ou "ein" (| = ou).

Source : http://www.lexique.org/?page_id=101
<https://buzut.net/la-puissance-des-regex/>

Expressions régulières (2/2)

- `[A-Za-z]` : n'importe quoi comme caractère, majuscule ou minuscule
- `+` : 1 ou plus
- `()` : contenu à extraire
- `\w` : un caractère alphanumérique ou un tiret de soulignement (tiret de 8).

Source : http://www.lexique.org/?page_id=101
<https://buzut.net/la-puissance-des-regex/>



Python vs. R: What's the Difference?

**What is the difference between
Anaconda Prompt and Anaconda
Powershell Prompt?**




• annexe

classification



regression







THANKS

Does anyone have any questions?


CREDITS: Fei GAO (EHESP)




Underfitting




Just right!




overfitting





Clustering
System



Créez votre compte Databricks

1/2

Prénom

Fei

Nom

GAO

E-mail professionnel

constance.fe.gao.pro@gmail.com

Entreprise

hdh

Intitulé de poste

DS

Numéro de téléphone (facultatif)

0661213981

Pays

France ▼

- ☐ Oui, je souhaite recevoir les communications marketing concernant les services, les événements et les produits open source de Databricks. Je suis conscient(e) que je peux modifier [mes préférences](#) à tout moment.

Continuer

Sélectionnez un fournisseur de cloud

2/2



Amazon Web Services



Microsoft Azure



Google Cloud Platform

Continuer

En cliquant sur « Essayer », vous acceptez la [Politique de confidentialité](#) et les [Conditions de service](#).

Vous n'avez pas de compte cloud ?

Community Edition est un environnement Databricks limité destiné à un usage personnel et à la formation.

[Essayer Community Edition →](#)

En cliquant sur « Essayer Community Edition », vous acceptez la [Politique de confidentialité](#) et les [Conditions de service](#) undefined.